

1. GİRİŞ

Kıyı alanları, insan etkileri ve doğal sebeplerden kaynaklanan dinamik değişiklerin olduğu, ekonomik ve sosyal açıdan nitelikli bölgelerdir. Mineral kaynakları, petrol-gaz kaynakları, gelgit-dalga enerji kaynakları ve diğer yenilenebilir enerji kaynakları bakımından yerleşimler kıyı alanlarında yoğunlaşmaktadır (Zhang vd., 2013). Kıyı bölgelerinde artan nüfusla birlikte, kıyı değişiminin incelenmesi araştırmacıların en önem verdiği konulardan biridir (Moore, 2000). Kıyı çizgisinde meydana gelen değişimlerin hızlı ve doğru bir şekilde belirlenmesi sadece kıyı ıslahı, kentsel büyüme ve liman geliştirme faaliyetleri için değil aynı zamanda denizcilik ekonomisi ve denizcilik araştırmaları için de önemli bir konudur (Zhang vd., 2013).

Kıyı çizgisini çıkartmak için fotogrametrik yöntemler, GPS teknolojisi ve yersel ölçüler, uzaktan algılama gibi çeşitli yöntemler kullanılmaktadır (Zhang vd., 2013). LANDSAT uydusunun 1972'de kullanılmaya başlanılmasından bu yana optik uzaktan algılama verileri diğer yöntemlerden elde edilen verilere bir alternatif haline gelmiştir (Gens, 2010). Kontrolsüz sınıflandırma teknikleri (ISODATA-Iterative Self Organized Data Analysis) bant oranlama, normalize edilmiş fark su indeksi (NDWI) eşik değeri ve morfolojik filtreleme, Wavelet dönüşümü, aktif kontur modelleri (Zhang vd., 2013), nesne tabanlı, genetik algoritma, kontrollü ve kontrolsüz sınıflandırma, parçacık sürü optimizasyonu (PSO), Mean-shift bölütleme (İncekara vd., 2018) optik uydu görüntülerinden kıyı çizgisi çıkarmak için kullanılan yöntemlere örnek olarak verilebilir. Son yıllarda makine öğrenmesi yöntemleri uzaktan algılama problemlerinde yaygın olarak uygulanmaktadır (Lary vd., 2016). Çeşitli çalışmalarda kıyı çizgisi çıkarımında makine öğrenmesi yöntemleri kullanılmıştır (Dixon & Candade, 2008; Kalkan vd., 2013; Bayram vd., 2017). Choung & Jo, 2017 Worldview-2 uydu görüntüleriyle bir makine öğrenmesi yöntemi olan Destek Vektör Makineleri (Support Vector Machines) ile adaptif eşikleme ve NDWI yöntemin kıyı çizgisi çıkarımındaki performansını araştırmıştır.

Derin öğrenme (DL), Goodfellow vd., 2016 tarafından bilgisayarların dünyayı kavram hiyerarşileri açısından anlamasını ve insanlara benzer şekilde karar vermesini sağlayan makine öğrenmesi olarak tanımlanmaktadır. Klasik makine öğrenmesinde özellik çıkartma işlemi kullanıcı tarafından yapılmaktadır ve bu zaman alıcı ve kullanıcı odaklı bir süreçtir. Derin öğrenme yaklaşımında ise özellik çıkartma işlemi otomatik olarak yapılmaktadır (Patterson & Gibson, 2017).

DL yöntemleri, son yıllarda kıyı alanlarına yönelik çalışmalarda yaygın olarak kullanılmaya başlanmıştır. Yang vd., 2015 LANDSAT uydu görüntülerinde SSAE (Stacked Sparse Autoencoder) derin öğrenme mimarisini kullanarak kara-su

bölütlemesi gerçekleştirmişlerdir. Yu vd., 2017 LANDSAT-7 görüntülerinden kıyı çizgilerini çıkarmak için evrimsel sinir ağları ve lojistik regresyon sınıflandırıcısından oluşan karma bir makine öğrenimi sistemi sunmuştur. Işıkoğan vd., 2017 DeepWaterMap adlı kodlayıcı-kod çözücü derin öğrenme mimarisine dayalı Tam Konvolüsyonlu Ağ (FCNN) yapısı kullanarak LANDSAT-7 uydu görüntülerinde kara-su bölütlemesi gerçekleştirmişlerdir. Li vd., 2018 kıyı çizgisi bölütlemesi için DeepUNet adlı genişleyen konvolüsyonel sinir ağları tabanlı bir yaklaşım önermiştir. Chen vd., 2018 süper piksel ve konvolüsyonel sinir ağı algoritmalarını kullanarak yüksek çözünürlüklü çok bantlı görüntülerden kıyı çizgisi çıkarmıştır. Song vd., 2020 Worldview-3 ve GeoFen-2 görüntülerinden Mask R-CNN yöntemini kullanarak su sınıfını yüksek doğruluklar ile üretmişlerdir. Erdem vd., 2020 tarafından yapılan çalışmada LANDSAT-8 görüntülerinden su sınıfının çıkarılması için WaterNet adında 5 farklı U-Net derin öğrenme modelinin kombinasyonu kullanan bir yöntem geliştirilmiştir.

Uzaktan Algılama çalışmalarında derin öğrenme modellerinin uygulanmasında aktarımlı öğrenme (transfer learning) yaygın olarak kullanılan bir yöntemdir. Aktarımlı öğrenme ile bir veri seti için yapılan eğitim işlemi sonucunda oluşturulan ağırlık parametresi, bir başka veri setinin eğitilmesi için başlangıç ağırlıkları olarak kullanılır. Bu durum, az sayıda veri ile yüksek doğrulukta sonuçlar üretmek açısından avantajlar sağlamaktadır (Torrey & Shavlik, 2009).

Yapılan literatür araştırmasında SENTINEL-2 görüntülerinden aktarımlı öğrenme yöntemi kullanılarak kara-deniz bölütlemesi ve kıyı çizgisi çıkartmaya yönelik bir çalışmaya rastlanmamıştır. Bu çalışmada, önceden LANDSAT-8 uydu görüntüleri ile eğitilmiş U-Net mimarisi (Erdem, vd., 2020) ve az sayıda SENTINEL-2 uydu görüntüsü veri seti kullanılarak aktarımlı öğrenme ile kıyı çizgisi çıkarılmıştır.

2. YÖNTEM

Bu çalışmada SENTINEL-2 veri setinden kara-deniz bölütlerinin U-Net mimarisi ile elde edilmesi için YTU-WaterNet açık veri seti (URL-1) ile eğitilen U-Net mimarisinin ağırlıkları (Erdem, vd., 2020) başlangıç ağırlıkları olarak kullanılmıştır.

2.1. Veri

Sunulan çalışmada, aktarımlı öğrenme için farklı kıyı bölgelerinden alınan 10m konumsal çözünürlüğe ve 15-bit radyometrik çözünürlüğe ve mavi, kırmızı ve yakın kızılötesi bant kombinasyonuna sahip toplam 15 adet SENTINEL-2 uydu görüntüsü kullanılarak eğitim ve test veri